INF5190 - Résilience et performance

Jean-Philippe Caissy

20 novembre 2019

Définition : capacité d'un système à récupérer d'une défaillance et rester opérationnel

- Une défaillance dans un système (application Web) va se produire éventuellement
- Plus un système est complexe, plus les risques de défaillances sont élevées
 - Une application avec 3-4 systèmes peut facilement être disponible 100% du temps vs. une application avec des centaines de composantes
- Un système est résilient s'il reste fonctionnel malgré une défaillance

Lors d'une défaillance, un système devrait être en mesure d'opérer en mode défaillance partiel.

Exemples:

- Amazon : la recherche ne fonctionne plus
- ► Netflix : les vidéos HD ne chargent plus
- ► Google : impossible de se connecter

La résilience d'une application Web se fait sur 4 niveaux différents :

- L'application elle-même
- Les données
- Le réseau
- Les gens et la culture organisationnelle

Patrons

Il existe plusieurs patrons à utiliser pour rendre une application résiliente.

Redondance

- Architecturer une application pour pouvoir rouler de manière redondante (plus d'une instance)
- La redondance s'applique à tous les niveaux :
 - Application Web
 - Base de donnée
 - Réseau
 - Employés
- ▶ La redondance permet d'éliminer les défaillances causés par un point de défaillance unique (SPOF, ou single point of failure)

Redondance



Figure 1: Composantes en série

La disponibilité d'un système en série est mesuré par la sommes de la disponibilité des deux systèmes.

| Composante | Disponibilité | Temps indisponible |
|------------|---------------|----------------------------------|
| A | 99% | 3 jours, 15 heures |
| В | 99.99% | 52 minutes |
| A et B | 98.99% | 3 jours, 16 heures et 33 minutes |

Résilience Redondance



Figure 2: Composantes en parallèles

$$D = 1 - (1 - Ax)^n$$

| Composante | Disponibilité | Temps indisponible |
|----------------------|---------------|--------------------|
| Un seul A | 99% | 3 jours, 15 heures |
| Deux A en parallèle | 99.99% | 52 minutes |
| Trois A en parallèle | 99.9999% | 31 secondes |

Mise à l'échelle automatique (auto-scaling)

- Automatiquement augmenter, puis diminuer les capacités d'un système
 - Mot clé : automatique, et non pas manuellement

Exemple : Diminuer le nombre de serveur applicatifs la nuit lorsque le trafique est très bas